Автоматическое построение и отбор признаков для рекомендаций

Следующий просмотр товара по полной известной истории пользователя. Сравнение ограниченного автоматического поиска с содержательным ручным градиентным бустингом.

Убедительный прирост автоматического отбора относительно ручной базы не установлен: интервал разности включает ноль.

Основное сравнение: оба семейства автоматически отобранных признаков против ручной базы. Разность NDCG@20: **-0.00018 [-0.00106; +0.00066]**, парный 95% интервал по пользователям.

В тесте **10 384 моментов прогноза** и **965 пользователей** за 25-30 октября 2019 года. Из исходного потока выбраны 5 000 пользователей; все их события за октябрь сохранены и независимо сверены с источником.

Вариант	Признаки	NDCG@20	Recall@20	Разность NDCG
Ручные признаки	108	0.40524	56.27%	+0.00000
Автоокна	120	0.40549	56.26%	+0.00025
Автосочетания	120	0.40567	56.38%	+0.00044
Оба семейства	132	0.40505	56.15%	-0.00018
Случайный контроль	132	0.40547	56.33%	+0.00023

Попадание следующего просмотренного товара в первые 20: **56.27% → 56.15%**; разность **-0.12 процентного пункта**.

NDCG@20 учитывает позицию одной наблюдаемой цели; Recall@20 показывает её наличие в первых 20. Основные строки используют ранжирование по средним исходным оценкам трёх моделей, а не среднее трёх метрик.

Положительный результат не является условием корректности исследования. Вывод относится к конкретному словарю признаков, способу отбора и выбранной задаче; истинный бюджет, покупки и выручка не измерялись.

Сравнение с простыми правилами

Правило / модель	NDCG@20	Recall@20
Прошлая популярность	0.02671	6.38%
Повторы по давности, затем категория	0.38192	49.67%
Ручной бустинг	0.40524	56.27%

Полная история выбранных пользователей

REES46, октябрь 2019: **42 448 764** событий и 3 022 290 пользователей в исходном файле. Детерминированно выбраны 5 000 пользователей с наименьшим хешем ID. Сохранены **71 429 событий** всех их посещений за месяц; отбор не зависит от покупок, активности и целевых товаров.

Повторное независимое чтение всего исходного файла подтвердило количество и канонический хеш каждой строки каждого выбранного пользователя. Это исправляет предварительный пилот, где отбирались отдельные посещения. Его результаты не объединяются с итоговыми.

Определение прогноза

После как минимум двух известных просмотров прогнозируется следующий просмотр в потоке пользователя, в том числе в другом посещении. В префикс входят все события до секунды отсечения включительно; цель строго позже. Неоднозначные цели с разными товарами в одну секунду исключены. Моменты без наблюдаемого следующего просмотра не оцениваются.

Часть	Дни октября	Доступно запросов	Выбрано / оценено
Train	2-20	37 704	10 000
Validation	21-24	6 982	3 000
Test	25-30	10 384	10 384

1 октября даёт начальную историю, 31-е служит правой защитой. Цели, пересекающие границы частей, исключены; сырые события не удаляются. Ограничение 10 000/3 000 выбирает моменты прогноза по хешу, сохраняя всю пользовательскую историю.

Кандидаты, цены и отрицательные примеры

200 одинаковых кандидатов: до 40 последних разных просмотренных товаров, до 80 популярных в категории последнего просмотра, затем общая популярность. Дневной каталог, атрибуты и популярность строятся по всем исходным событиям строго до начала дня. В текущем префиксе допустимо обновить уже наблюдавшуюся цену.

Цель есть в кандидатах в **72.05%** тестовых запросов. Она не добавляется принудительно; непокрытые запросы получают ноль. В обучении используются 7 119 покрытых запросов: одна цель и 40 фиксированных отрицательных кандидатов, всего 291 879 строк.

REES46 выбран для исследования типов действий и ценового контекста категории. Это обоснованная альтернатива предложенным KION/Yambda. Отсутствие показов не позволяет интерпретировать отрицательные примеры как отсутствие клика после показа или как неприязнь к товару.

Из словаря операций - в выбранные признаки

Содержательная ручная база

105 числовых и 3 категориальных признака: активность, разнообразие и повторы; категория, бренд, цена, возраст и популярность товара; прямые взаимодействия с кандидатом; косвенные связи с категорией/брендом; ценовой контекст. Фиксированные окна: 3/10 действий, вся известная история, один и семь дней. Цены сопоставляются внутри категории; пропуски обрабатываются явно.

Генерация и отбор

1. Перечисление. Генерируются 112 агрегатов: 7 окон (2/5/20 действий и 1/5/15/30 минут) × 16 статистик. Ещё 48 сочетаний описывают ценовую близость, категорию, бренд, корзину и изменение контекста. Арифметика над ID запрещена.

2. Подготовка на train. Определяются медианы, границы 1-99% для отсечения выбросов и корреляции на фиксированной подвыборке строк. Константы и почти точные копии ручных признаков исключаются.

3. Оценка на validation. Три ручных бустинга дают средние оценки. Для каждой покрытой группы рассчитывается остаток между целью и softmax-оценкой кандидатов. Признак оценивается по согласованности с остатками отдельно за 21-22 и 23-24 октября.

4. Выбор. Сохраняется до 12 признаков каждого семейства со стабильным знаком эффекта, без почти дублирующих выбранных признаков внутри семейства (|correlation| > 0,995). Совпадения разрешаются детерминированно по имени.

5. Контроль. Случайный набор имеет те же размеры семейств и тот же отсев дубликатов; качество не используется при случайном выборе. Автоокна и автосочетания отдельно показывают вклад компонентов.

Семейство	Сгенерировано	Выбрано	Случайный контроль
Оконные агрегаты	112	12	12
Сочетания	48	12	12

Список выбран один раз и одинаков для всех запросов. Значения признаков обновляются по текущему префиксу; персональное переключение окон для каждого запроса в этот итоговый метод не входит.

Примеры фактически выбранных признаков

auto_e5_item_views, auto_m1_abs_price_delta_category_median

auto_cross_w10_price_closeness, auto_cross_wall_price_closeness

Человек задаёт пространство допустимых операций; алгоритм автоматически перебирает и отбирает варианты. Это ограниченная автоматизация, а не свободное создание любых формул или доказательство новизны самой идеи. Полный рейтинг, выбранные признаки и причины отсева: results/feature_screening.csv.gz.

ЭКСПЕРИМЕНТ / УСТОЙЧИВОСТЬ

Одинаковые условия сравнения

Все пять вариантов: CatBoostRanker, QuerySoftMax, 261 дерево глубины 6, learning_rate 0,06, l2=5, три seed 20261022/23/24, 4 потока на модель. Параметры зафиксированы по пилотной разработке; дополнительного поиска не было. Ранней остановки нет. Категориальные счётчики SkipTest не используют validation. Отбор признаков использует validation; итоговый тест открывается после фиксации исходников, моделей и отбора.

Проверка по seed

Seed	Ручная база	Оба семейства	Разность NDCG
20261022	0.40499	0.40479	-0.00020
20261023	0.40480	0.40450	-0.00030
20261024	0.40447	0.40546	+0.00099

Шесть последовательных тестовых дней

День	Запросы	Ручная база	Оба семейства	Разность
2019-10-25	2 422	0.42251	0.42185	-0.00066
2019-10-26	1 602	0.40226	0.40174	-0.00052
2019-10-27	1 509	0.37247	0.37182	-0.00064
2019-10-28	1 695	0.40854	0.40720	-0.00135
2019-10-29	1 551	0.37799	0.37915	+0.00116
2019-10-30	1 605	0.43577	0.43702	+0.00124

Основной 95% интервал: **-0.00018 [-0.00106; +0.00066]**. Использованы 2 000 парных бутстрэп-повторов по 965 пользователям: все запросы одного человека, включая разные дни, остаются в одном кластере. Интервал условен на обученных моделях; это не оценка всей неопределённости переобучения. Семена и дни не являются независимыми наборами данных.

Повторные и ранее не просмотренные цели

Цель в истории	Запросы	Покрытие	NDCG базы	Recall базы
Уже просмотрена	5 021	98.43%	0.76622	93.63%
Ещё не просмотрена	5 363	47.36%	0.06727	21.29%

Описательное разбиение по фактической цели: повторные просмотры предсказываются существенно лучше. Для новых целей ограничение возникает уже при подборе кандидатов; общий Recall нельзя переносить на поиск новых товаров. Интервал с нулём не доказывает равенство или неухудшение: допустимая граница потерь заранее не задавалась.

Стоимость ограниченного поиска

Вариант	Признаки	Сумма fit, 3 seed	Пик RSS процесса
Ручные признаки	108	13.1 мин	2.07 ГиБ
Автоокна	120	13.6 мин	2.15 ГиБ
Автосочетания	120	13.6 мин	2.01 ГиБ
Оба семейства	132	13.7 мин	2.30 ГиБ
Случайный контроль	132	13.7 мин	2.34 ГиБ

Сумма fit не равна настенному времени: до двух моделей обучаются параллельно. RSS относится к одному процессу с его входными таблицами, а не ко всей машине. Используется CPU; GPU не требуется.

Этап	Фактическая стоимость
Чтение источника и полная выборка	260.0 с
Независимое повторное чтение источника	112.5 с
Ручные и все генерируемые признаки train/validation	160.6 с
Отбор на validation	2.9 с
Итоговый тест: признаки и все модели	131.8 с

Откуда берётся дополнительная стоимость

На тесте расчёт ручных признаков и retrieval занял 57.7 с, генерация полного дополнительного словаря - 26.5 с. Общие стадии считаются один раз и разделяются всеми вариантами; время построения таблиц и предсказания трёх моделей каждого варианта записано отдельно в test_results.json.

Масштабируемость и ограничения прототипа

Расходы растут с числом моментов прогноза, кандидатов, длиной префиксов и шириной словаря. Прототип повторно обходит префиксы и даже после отбора вычисляет весь словарь; это избыточно для промышленного применения. Возможные оптимизации - накапливаемые агрегаты, вычисление только выбранных признаков и их зависимостей, пакетный расчёт по пользователям.

Эксперимент не измеряет производительность на миллиардах событий. Рабочие матрицы воспроизводятся и не входят в архив. При переходе к большим данным необходимо отдельно измерить обучение, память и онлайн-задержку; качество небольшой выборки не гарантирует тот же эффект в полном потоке.

Что установлено и что остаётся открытым

Убедительный прирост автоматического отбора относительно ручной базы не установлен: интервал разности включает ноль.

Оба семейства минус случайный контроль: **-0.00042 [-0.00127; +0.00045]**. Если интервал включает ноль, преимущество самого критерия отбора над случайным набором данного размера не установлено.

Разбор компонентов

Автоокна минус ручная база: **+0.00025 [-0.00048; +0.00105]**.

Автосочетания минус ручная база: **+0.00044 [-0.00053; +0.00152]**.

Возможные объяснения, требующие отдельных проверок

Ручная база уже содержит несколько окон и содержательные взаимодействия; бустинг способен учить часть сочетаний самостоятельно. Словарь ограничен заданными операциями. Критерий согласованности с остатками не оптимизирует NDCG напрямую и может хуже переноситься на будущие дни. Эти объяснения правдоподобны, но не установлены как причины одним сравнением.

Границы результата

Один рынок и месяц; 5 000 пользователей в исходной выборке и меньшая активная тестовая подгруппа; ограниченный train; приближённый каталог и 200 кандидатов. Задача условна на наблюдаемом следующем просмотре. Метрика усредняется по запросам, а не поровну по людям. Случайный контроль - один фиксированный набор признаков; три seed относятся к обучению моделей. Групповые интервалы описательные. Истинный бюджет, продажи и эффект внедрения не измеряются.

Следующая проверка

Отдельно сравнить критерий отбора с прямой оптимизацией качества ранжирования при фиксированном бюджете, а переносимость - на новом времени или другом наборе. Увеличивать выборку пользователей с сохранением всей истории. Новые решения потребуют нового отложенного периода.

Воспроизведение и проверка

Установить requirements.txt. В обоих архивах python verify.py --outputs-only проверяет сохранённые прогнозы и интервалы. В полном архиве python verify.py также проверяет данные и модели; повтор: python run_pipeline.py --output /path/new_run. В небольшом архиве для полного повтора нужен --download. Подробности: README.md, PROTOCOL.md и test_gate.json.

Проверены 72 688 списков топ-20 и 228 448 списков рангов. Метрики воспроизводятся по ID товаров и рангам; первичный интервал и сравнение со случайным контролем пересчитаны независимо.

Использование инструментов

ChatGPT/Codex использовались для протокола, кода, проверок, вычислений и подготовки материалов. Исходная мотивация учитывать текущий ценовой интерес и смысл действий предложена кандидатом; ограничения и интерпретация обсуждались совместно. Автоматический поиск признаков внутри эксперимента реализован отдельным алгоритмом.

Источники: REES46 - https://data.rees46.com/ ; CatBoost ranking objectives - https://catboost.ai/docs/en/concepts/loss-functions-ranking .